Как оптимизация прогноза досмотра меняет рекомендации KION

Предсказание следующего фильма, модель досмотра и дополнительное обучение рекомендателя. 25 октября 2026 года.

Можно ли улучшить рекомендации, если после обучения на следующем просмотре оптимизировать прогноз досмотра? В отдельной диагностике исходного опыта модель научилась выбирать фильмы с более высокой предсказанной наградой. Улучшение рекомендаций по наблюдаемому следующему просмотру не установлено. Лучший результат остался у ранжирующей модели с дополнительными признаками до такого обучения. Поправка награды на средний досмотр фильма дала меньшую потерю качества, чем прямой прогноз досмотра, во всех трёх проверенных парах запусков, однако доверительный интервал разности включает ноль.

Практический результат работы состоит в проверке этого расхождения целей. Рост прогноза досмотра сам по себе не обосновывает замену исходного рекомендателя. Пятишаговая генерация дополнительно показала повторы в выдаче, но не проверяла реальные реакции пользователей или их возвращение.

Данные и оценка

Использован открытый KION: взаимодействия пользователей, каталог и пользовательские признаки за март–август 2021 года. Объектом рекомендации служит фильм или сериал. Запись взаимодействия агрегирует просмотры одной пары «пользователь, фильм». Дата относится к последнему взаимодействию, а длительность и процент просмотра собраны по просмотрам пары. Поэтому строку нельзя считать отдельной сессией, а порядок дат не восстанавливает полную историю событий. Точная формула агрегации процента в описании релиза не раскрыта.

Обучающая часть содержит записи до 9 августа. Оценочная выборка охватывает 9–15 августа, тестовая отведена под 16–22 августа. При оценке следующего фильма история зафиксирована до начала оценочного периода и содержит не более 63 прежних объектов. Фильм, просмотренный в тот же день, что и целевой, не добавляется в историю: порядок хранения записей внутри дня не выдаётся за порядок действий пользователя.

Общее сравнение выполнено на 4096 запросах от 4035 пользователей. В каждом запросе один наблюдаемый следующий фильм. Оценочная выборка неоднократно использовалась при разработке, а тестовая ранее открывалась. **Нового независимого тестового набора здесь нет.** Результаты описывают качество на использованных данных; доверительные интервалы эту границу не устраняют.

Каждому запросу соответствует естественный набор из 1024 кандидатов. Он собирается из GPT, популярных за предыдущие семь дней фильмов и ItemKNN, который ищет соседние объекты по взаимодействиям. Источники добавляют соответственно 512, 256 и 256 уникальных объектов после учёта пересечений. Правильный ответ специально не вставляется, ранее просмотренные фильмы не исключаются. Набор содержит наблюдаемый следующий фильм примерно в 82% запросов. Фильмы вне словаря модели и известные ей фильмы вне набора остаются промахами в общем знаменателе. Так оценка учитывает и ограничение поиска кандидатов, и качество их ранжирования.

Как устроена система

Сначала GPT архитектуры GPT-2 учится предсказывать следующий item-ID по истории. Представления фильмов дополнены признаками каталога, включая текст и участников; пользовательские признаки входят в начальный токен. Модель обучена на **3 477 437 подготовленных примерах за две полные эпохи**. После этого GPT и таблица представлений фильмов заморожены: их веса больше не меняются.

Над их выходами отдельно обучены три ранжирующие головы: небольшие сети для переупорядочивания кандидатов. Каждая добавляет поправку к исходной оценке GPT. У всех есть представления истории и кандидата, их взаимодействие, текущая оценка GPT и недавняя популярность. Различается дополнительный блок признаков:

- A не использует этот блок, но сохраняет информацию об истории через GPT.
- B добавляет локальные динамические признаки и внешние интересы.
- C также использует персональные, связанные с объектами и франшизные признаки.

Например, B учитывает недавнюю частоту взаимодействий с фильмом и просмотры его статьи Wikipedia, а C дополнительно учитывает знакомых пользователю актёров и уже просмотренные части франшизы.

Каждая голова обучена на 262 144 выбранных примерах за три эпохи. Это существенно меньший объём, чем обучение GPT. Повторные эпохи не создают новых уникальных примеров. На обучающем примере положительный фильм сравнивается с 31 фиксированным отрицательным кандидатом; оценка проводится на полном наборе кандидатов. Головы обучены независимо при общем порядке данных и настройках. Разность C и B характеризует такое расширение модели, но не устанавливает причинный вклад отдельного признака.

Далее отдельная модель CatBoost прогнозирует досмотр по истории пользователя и признакам кандидата. Эта модель далее обозначается RM. Её прогноз становится наградой для дополнительного обучения копии головы C. Исходная C остаётся неизменным эталоном. На этой стадии меняются только параметры обучаемой копии; GPT, представления фильмов и модель досмотра фиксированы. Таким образом, цепочка состоит из поиска кандидатов, ранжирования по известным следующим просмотрам и последующей оптимизации заданной награды.

Сравнимый результат

Основная метрика MAP@10 оценивает позицию наблюдаемого следующего фильма. Вклад запроса равен 1/rank, если этот фильм вошёл в первые десять позиций, и нулю в остальных случаях. Чем раньше найден правильный фильм, тем выше вклад. Это метрика следующего выбора, а не оценка процента досмотра.

В таблице все модели используют одни запросы и кандидатов. RL обозначает дополнительное обучение по награде: completion использует прогноз досмотра, residual вычитает из него обычный для фильма уровень. Эти строки относятся к завершённой проверке с сопоставимым отклонением от C, описанной ниже. Значения округлены; точные результаты доступны в анализе исходных голов и анализе сопоставимых RL-запусков.

Модель	MAP@10
GPT	0,0723
A	0,0829
B	0,0865
C	**0,0969**
RL completion, среднее трёх запусков	0,0944
RL residual, среднее трёх запусков	0,0963

Добавление признаков в C улучшило результат относительно GPT и более простых голов на этой оценочной выборке. Интервал разности MAP между C и B, рассчитанный с группировкой запросов по пользователям, целиком выше нуля. После оптимизации награды точечное качество следующего выбора оказалось ниже исходной C. Средние RL-строки описывают результаты трёх отдельных политик, а не ансамбль. Значения для каждой пары приведены в техническом приложении.

Что предсказывает модель досмотра

CatBoost обучен на наблюдаемых значениях watched_pct/100. Его выход представляет непрерывную долю досмотра. Это не вероятность события «пользователь досмотрит фильм полностью». Для неизвестной пары «пользователь, фильм» отсутствующий исход не заменяется нулём.

Модель обучена на 100 тысячах наблюдений. Отдельные выборки использованы для выбора версии и калибровки, затем выполнена проверка на 20 тысячах более поздних наблюдаемых исходов. Объёмы и роли всех выборок указаны в подробном разбиении технического приложения. Ошибка прогноза (RMSE, меньше значит лучше) калиброванной модели составила 0,352 против 0,371 у контрольного прогноза, построенного по историческим средним. Следовательно, модель содержит полезный предсказательный сигнал. При этом калибровка немного ухудшила поздний RMSE относительно тех же деревьев без калибровки; идеальная согласованность прогноза и исхода не достигнута. Подробная оценка RM.

Для фильмов без валидных наблюдений в обучении используется общий средний досмотр. На таких фильмах заметна ошибка переноса. Наличие хотя бы одного наблюдения фильма задаёт техническую границу применения награды, но не гарантирует точность прогноза для конкретного пользователя. Даже хорошая ошибка на просмотренных фильмах не доказывает качество прогноза для произвольного непоказанного кандидата: у такого показа нет наблюдаемого исхода.

Есть и временное ограничение. RM обучена на исходах до 2 августа, а её калибровка использует неделю 2–8 августа. GPT обучен на всей подготовленной обучающей части до 9 августа. Обе модели затем используются при дополнительном обучении ранкера на данных той же недели. Кроме того, точная историческая доступность внешних признаков и агрегированного досмотра восстановлена не полностью. Поэтому опыт проверяет offline-оптимизацию фиксированных моделей. Он не воспроизводит систему, располагавшую на каждой ранней дате только тогда доступной информацией.

Две награды и контроль силы изменения

Completion напрямую использует прогноз RM. Residual вычитает из него сглаженный средний досмотр данного фильма, рассчитанный по обучающей части RM. Такая награда выделяет превышение над обычным для фильма уровнем. **Средний досмотр отличается от популярности:** первый описывает долю просмотра, вторая отражает частоту взаимодействий. Вычитание среднего не устанавливает индивидуальный причинный эффект рекомендации.

Голова обучается увеличивать ожидаемую награду с ограничением отклонения от C. Отклонение измеряется KL: оно показывает, насколько изменилось распределение вероятностей выбора кандидатов. Коэффициент β задаёт цену такого изменения. Награда центрируется относительно C: её исходное ожидаемое значение равно нулю по определению. Последующий рост нельзя читать как прибавку реального досмотра в процентных пунктах.

Оптимизация одношаговая: для каждой истории вычисляется ожидание по всем кандидатам. Весь набор RL состоит из 512 разных начальных историй. Для обновлений из него многократно выбираются пакеты; каждая финальная голова проходит 1000 обновлений. Здесь нет обученной модели переходов или обучения по пятишаговой награде. Для кандидатов без валидных наблюдений в обучении RM центрированный вклад награды обнулён технически; это не означает наблюдаемый нулевой досмотр.

В **исходном опыте обе награды использовали β=0,5**. На отдельной диагностической выборке из 256 запросов модельная награда completion выросла, качество следующего выбора снизилось, а самая частая первая рекомендация стала встречаться чаще. Для выбора версии заранее ограничили допустимую потерю качества и изменение выдачи. По этим правилам выбрали исходную C; финальная версия после обновлений всё равно включена в научное сравнение. Residual при том же β менял политику слабее, поэтому его близость к C могла объясняться меньшей силой воздействия.

Последующая проверка устранила часть этой неоднозначности. Для completion сохранён β=0,5, для residual по KL на обучающих состояниях выбран β≈0,1627. MAP оценочной выборки при выборе коэффициента не использовалась. Все три пары вошли в заранее заданный допуск сопоставимости KL. Первая пара участвовала в калибровке коэффициента, две следующие обучены после его фиксации. Между парами менялся только поток выбора обучающих состояний; данные, инициализация и остальные настройки сохранялись.

Средняя разность MAP residual относительно completion равна +0,0019 с 95% интервалом [−0,0009; +0,0045]. Интервал включает ноль, как и интервал residual относительно C. Превосходство residual не установлено; равенство политик также не доказано. При расчёте интервала методом bootstrap повторно выбираются пользователи вместе со всеми их запросами. Так оценивается пользовательская

неопределённость при этих обученных головах. Эта процедура не описывает всю вариативность обучения и не делает повторно использованную оценочную выборку независимым тестом.

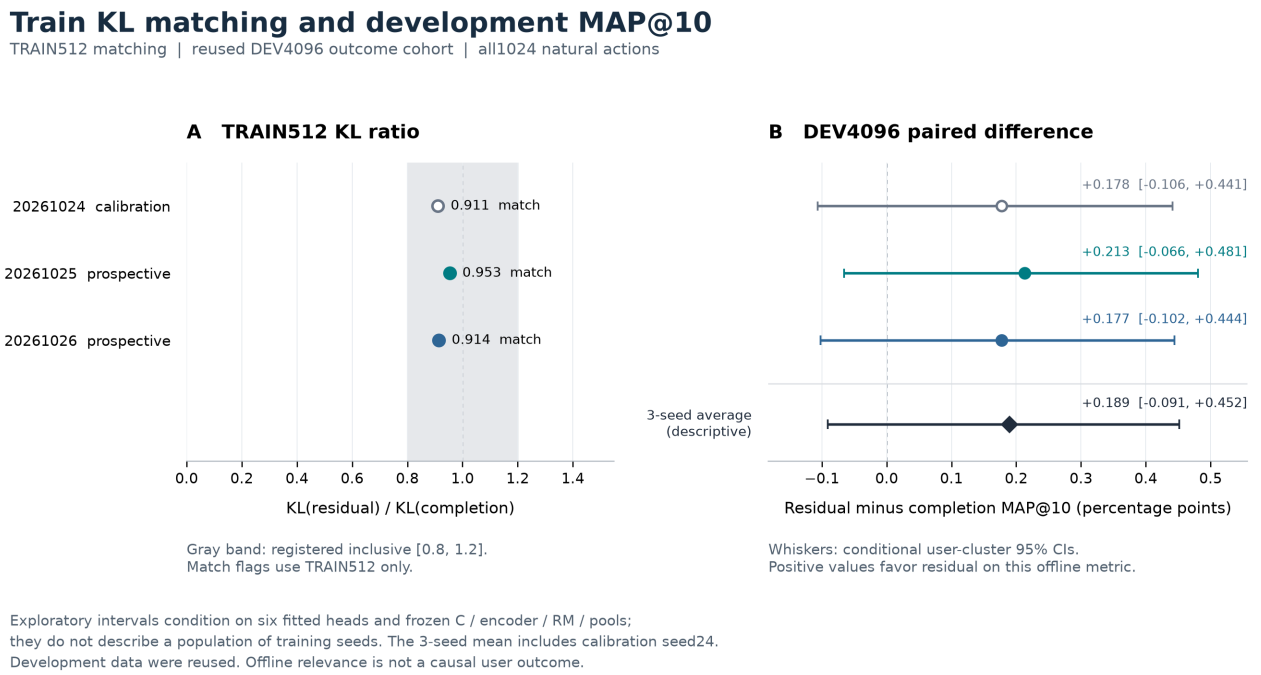


Рисунок 1. Сопоставимость KL на обучающих состояниях и пользовательская неопределённость разности MAP

Слева показан допуск отношения KL, справа разности MAP в процентных пунктах. Первая пара калибровочная, следующие две новые. Все показанные интервалы разности включают ноль.

Сопоставимый средний KL не уравнивает изменения каждого состояния или путь оптимизации. Это ограниченный контроль масштаба, а не доказательство причинного эффекта выбора награды. На отдельной диагностической выборке из 256 запросов у residual по сравнению с completion ниже максимальная доля одного фильма на первой позиции, но выше концентрация по всем позициям top10. Поэтому общего улучшения разнообразия результаты тоже не устанавливают.

Что показали пять рекомендаций подряд

Для исходных C, completion и residual с β=0,5 выполнена генерация по пять шагов на 16 заранее выбранных контекстах. Проверены жадный выбор и случайное семплирование, каждый с запретом повторов и без него. Получено 192 траектории. Новые головы с сопоставимым KL в эту диагностику не входили.

Выбранный item-ID действительно добавляется в историю, после чего GPT пересчитывает её представление и оценки. Поэтому это последовательная генерация с меняющейся текущей историей. Однако набор кандидатов остаётся исходным; новый поиск не проводится. Дополнительные признаки, время и состояние пользователя для RM зафиксированы в начальном состоянии. Сгенерированному фильму не приписываются просмотр, процент досмотра или новая дата.

При жадном выборе без запрета повторов каждая политика выдавала в среднем меньше двух уникальных фильмов из пяти. При семплировании повторов было значительно меньше. Запрет уже сгенерированных объектов обеспечил пять разных фильмов по конструкции. Такое различие показывает роль способа выбора и маски; его нельзя приписать обучению разнообразию.

Подробные графики отдельно показывают повторы сгенерированных фильмов и выбор из прежней истории. Пользовательские исходы на шагах 2–5 отсутствуют.

Суммарная дисконтированная награда рассчитана по фиксированной RM начального состояния. Она описывает модельную оценку последовательности, но не измеряет просмотренную длительность или возвращение пользователя. Без исходов последующих шагов нельзя оценить их релевантность по наблюдаемому ответу. Эта проверка обнаруживает поведение уже обученных одношаговых политик; обученная пользовательская среда и многошаговое RL здесь не строились.

Долгосрочная цель и воспроизводимость

Наградой за долгосрочную пользу мог бы служить факт возвращения в заданное окно или число активных дней. Сначала нужны определение визита, окно возврата и правила правого цензурирования. Потребуются логи показов и сессий, доступность фильмов, реальные отклики после рекомендации и либо онлайн-рандомизация, либо обоснованная процедура off-policy оценки с вероятностями показов. Иначе отсутствие следующего просмотра смешивает уход пользователя, конец периода наблюдения и неполный лог.

Агрегированные пары KION не дают таких данных и не восстанавливают результат показа другого фильма. Поэтому работа не подтверждает рост удержания, удовлетворённости или реального досмотра. Она показывает, как выбор модельной награды меняет ранжирование, и где доступных наблюдений недостаточно для долгосрочного вывода.

Полные параметры, дополнительные метрики и результаты отдельных стадий сохранены в техническом приложении; границы выводов собраны в ограничениях. Индекс доказательств связывает выводы с сохранёнными результатами. Исходники и REPRODUCING.md описывают код, проверки Git-клона и отдельные входы для воспроизведения. В клоне есть код, компактные результаты и рисунки; численные веса и входы малого replay передаются отдельно. Исторический ограниченный replay не означает полного повторения обучения или всего исследования на новой машине.